

제6회 K-인공지능 제조데이터 분석 경진대회

X-ray 이물 검출 모델 6종을 비교하고 일반화·강건성까지 검증해 베스트 모델을 선정하다

영상 기반 완제품 이물질 탐지 및 AI 미탐지 조건 분석



팀명: [확정 필요]

허민엽 · 정연창 · 이총

문제와 데이터


약 10px의 작은 점(금속구)을 찾는 검출 문제, 이미지는 모두 NG 판정

- X-ray 이물 검출기 영상 **2,532장**, 박스 4,494개
- 호기 3종, 해상도 4종 (316x332 ~ 576x444)
- train 1,767 / val 369 / test 396장 (연속 촬영 묶음 단위, 시드 42)
- **라벨이 두 종류**: 공식 500장은 사람이 그려 크기가 제각각(5~21px), 팀 라벨 2,032장은 클릭 중심에 고정 크기 네모(**10·13px**)를 자동 생성
- 정상 이미지가 없다(빈 라벨 105장은 제품이 반만 찍힌 사진)
- 장비의 색 표시는 지운 이미지를 사용



실험 흐름

학습·평가 → 못 찾은 것의 원인 → 일반화·robust 평가 → 베스트 모델



- 모델 6개: 베이스라인 YOLOv3-tiny, Faster R-CNN(ResNet-50, MobileNetV3), 팀원 모델 YOLO26n · RT-DETR-l · D-FINE-N
- 모든 모델을 **같은 평가 코드**로 채점하고, 임계값은 val에서 정해 고정, test는 한 번만 본다

① 학습 · 검증 · 평가

지금 있는 데이터로 6개 모델을 같은 조건에서 학습하고 평가했다

모델	입력	학습 설정	val 임계값
YOLOv3-tiny (베이스라인)	640	COCO 사전학습, 100 epoch	0.06
Faster R-CNN ResNet-50	640	COCO 사전학습, 20 epoch(선택 7)	0.95
Faster R-CNN MobileNetV3	640	COCO 사전학습, 20 epoch(선택 18)	0.93
YOLO26n (팀원)	1024	COCO 사전학습, 40 epoch	0.42
RT-DETR-I (팀원)	640	COCO 사전학습, 최대 30 epoch(계획)	0.74
D-FINE-N (팀원)	640	학습 설정 기록 [확인 필요]	0.66

- 같은 데이터·분할, 같은 평가 코드
- 임계값은 모델마다 **val**에서 **F1 최대**로 정해 고정
- **test**는 한 번만 평가
- 팀원 모델은 가중치를 받아 같은 코드로 다시 평가(임계값도 다시 선정)

결과: 몇 개를 못 찾았다


F1은 0.986~0.991, 정답 663개 중 6~9개를 놓쳤고 거의 전부 공식 라벨 이미지다

모델 (test, IoU 0.5)	F1	못 찾음(FN)	그중 공식 라벨 이미지
YOLOv3-tiny (베이스라인)	0.989	7	7
Faster R-CNN R50	0.989	7	7
Faster R-CNN MobileNetV3	0.986	9	8
YOLO26n	0.991	6	6
RT-DETR-I	0.988	8	7
D-FINE-N	0.989	7	7

- 공식 라벨만 보면 F1은 0.96대로 내려간다
- FP도 같은 수 → 같은 점을 **어긋난 박스**로 낸 것
- → 정말 놓친 것일까? 놓친 자리를 직접 확인했다

원인: 공식 라벨의 박스 크기


놓친 것이 아니라 정답 박스의 크기가 달라서 IoU가 0.5에 못 미친 것이다



- 오류가 난 이미지는 거의 전부 공식 라벨(사람이 그려 크기가 제각각)
- 확대하면 모델 박스는 점을 정확히 감쌌(중심 거리 0.5~1.2px)
- 정답 박스가 더 작거나(6x7, 9x5) 더 큼(14x15)
- 팀 라벨은 고정 크기라 IoU가 잘 맞아 점수가 부풀려진다

해결: 중심 거리로 재채점

중심이 정답에서 $R(px)$ 이내면 찾은 것으로 보면 거의 다 찾는다



- $R = 5px$ 로 재채점하면 못 찾은 것이 4개 모델은 **0개**, MobileNetV3·RT-DETR-I은 **1개**
- $R \geq 3px$ 에서 6개 모델의 F1은 **0.998~1.000**(포화)
- IoU 0.5는 사실상 "중심이 2px 이내인가"를 재고 있었다
- 남은 차이는 위치 정밀도: mAP50-95는 D-FINE-N 0.659 > RT-DETR-I 0.639 > YOLO26n 0.633 > R50 0.611 > MobileNetV3 0.559 $\approx$ YOLOv3-tiny 0.558 (공식 라벨만 보면 0.335~0.365로 좁아짐)

② 일반화와 robust 평가

실제 데이터에서는 다 찾으니, 조건을 인위적으로 바꿔 모델을 시험한다



시험	묻는 것	방법
점 제거	모델이 결함의 점 자체를 보는가, 위치나 주변만 보는가	정답의 점을 보간으로 지운 이미지에 다시 적용
가짜 정상	결함이 없는 이미지에서 오경보를 내는가	점을 지운 이미지(결함 369장)를 가짜 정상으로 사용
합성 점	열은 점.다른 호기에서도 찾는가	작대기 안에만 점을 합성(진하기 4 x 크기 3), 시드 42
호기.해상도	특정 호기나 해상도에서 약한가	호기.해상도별로 나눠 평가

- 합성.가짜 정상은 **인위적인 이미지**라 실제 현장 성능이 아니라 **모델 간 상대 비교와 취약점 탐색**으로 해석한다

점 제거: 모델은 점 자체를 본다

결함의 점을 지우면 검출이 사라진다 → 위치만 보는 지름길이 아니다

점을 충분히 지우면 검출이 사라진다 → 모델은 점 자체를 본다 (위치만 보는 지름길이 아님)




- test 정답 663개의 점을 보간으로 지우고 같은 모델을 다시 적용: 노이즈 없는 평균 보간으로 13x13 이상 지우면 **6개 모델 모두 0~3개만 검출**
- YOLOv3-tiny 등에 남는 반응은 보간에 더한 **노이즈 무늬** 때문 → 다음 질문: 노이즈 무늬에 속아 오경보를 내는가?

가짜 정상: 노이즈 보간에는 R50과 YOLO26n만 속지 않는다

정상 이미지가 없어 결함의 점을 지운 이미지로 오경보를 잤다

점 제거와 가짜 정상 시험: 6개 모델 (test 결함 369장, 점 663개, 모델마다 val 임계값)




- NS+노이즈 6px 오경보율: **R50 0.5%, YOLO26n 4.1%**, RT-DETR-L 37%, YOLOv3-tiny 39%, D-FINE-N 49%, MobileNetV3 64%
- 오경보는 대부분 **지운 자리에서 발생**, 분리도(AUC)는 MobileNet 0.842·D-FINE 0.900이 가장 나쁨

가짜 정상은 진짜 정상 제품이 아니다. 오경보율은 범위로 해석한다.

합성 점: 작대기 안에만, 시드 42로 모두가 같게

실제로는 농침이 사실상 없어서, 미탐지 조건을 직접 만들어 시험했다






- 실제 점을 지우고 영상에서 찾은 작대기(막대) 안쪽에만 val의 실제 점(투과율 조각)을 합성
- 점의 진하기(4단계) x 크기(3단계)를 바꿔 열린 점까지 시험
- test 바탕 386장, 점 1,436개. 실제 점 663개가 전부 검출된 막대에 닿음
- 시드 42 + 이미지 이름별 시드로 고정, 기준본과 --verify로 팀원 PC에서 같은 데이터인지 확인
- 합성은 실제보다 약 10%p 덜 현실적 → 절대 수치가 아닌 상대 비교

합성 점 결과: 옳은 점이 미탐지 조건이다

val 임계값에서는 D-FINE-N이 앞서지만 대부분 느슨한 임계값 효과, 맞추면 차이가 줄어든다

합성 점(작대기 안, 시드 42) 평가: 6개 모델




- 대비(둘레-점 밝기) 6 미만은 모든 모델이 거의 0%, 20 이상에서 약 77~89%
- 임계값과 무관한 합성 점 AP: **D-FINE-N 0.574** $\approx$ **R50 0.567** > YOLOv3-tiny 0.515 $\approx$ YOLO26n 0.501 > RT-DETR-L 0.451 > **MobileNetV3 0.262**
- 3호기(대비 14 이상): MobileNetV3 4%, YOLO26n·RT-DETR-L 약 61%, R50·YOLOv3-tiny·D-FINE-N은 호기 차이가 작음

호기·해상도: 뚜렷한 효과는 확인되지 않았다

가장 낮은 그룹은 공식 라벨 박스가 76%여서 IoU 점수가 낮을 뿐이다

호기·해상도별 성능 (test, 모델별 val 고정 임계값). x축 아래 '공식 N%' = 그 그룹의 공식 라벨 박스 비율(라벨 크기가 제각각이라 IoU 점수가 낮아짐). *412x332는 박스 2개뿐



- 해상도별 공식 라벨 박스 비율이 10~76%로 달라 라벨 구성이 섞인다. 공식 라벨 이미지끼리만 비교하면 F1이 0.956~0.977로 좁아지고 구간이 겹친다
- 그룹별 표본이 작다(공식 라벨 이미지 호기별 20~36장). 합성 점에서 보인 3호기 약점은 모델에 따라 다르다(앞 슬라이드)

③ 종합: 모델별 성적표

한 모델이 모든 항목에서 1등은 아니다

모델	test F1 (IoU 0.5)	val mAP50-95 (전체 / 공식만)	가짜 정상 오경보 (NS+노이즈 6)	합성 점 AP	3호기 합성 점 (대비 14 이상)	파라미터
D-FINE-N	0.989	0.655 / 0.343	49.3%	0.574	89%	3.7M
RT-DETR-I	0.988	0.662 / 0.357	36.6%	0.451	61%	32.8M
Faster R-CNN R50	0.989	0.615 / 0.337	0.5%	0.567	75%	41.4M
YOLO26n	0.991	0.642 / 0.314	4.1%	0.501	62%	2.5M
YOLOv3-tiny	0.989	0.579 / 0.311	38.5%	0.515	70%	8.7M
Faster R-CNN MobileNetV3	0.986	0.583 / 0.322	64.0%	0.262	4%	19.0M

- 점 제거는 6개 모델 모두 0~3개만 남아 차이가 없다. test F1은 모두 포함다.

베스트 모델: D-FINE-N


val 동률 선두 + 미탐지 강건성 최상 + 작다(3.7M)

- ① **val mAP50-95**: val 이미지 복원추출 1,000회로 비교하니 **RT-DETR-I 0.662**와 **D-FINE-N 0.655**가 동률 선두(차이 -0.008 , 95% 구간 $-0.016 \sim 0.000$). R50(0.615)·YOLO26n(0.642)은 유의하게 낮음. 공식 라벨만 보면 R50도 동률
- ② **동률이면 강건성**: 합성 점 AP와 3호기 검출은 D-FINE-N이 우세(0.574 대 0.451, 89% 대 61%), 가짜 정상 오경보는 RT-DETR-I이 우세(37% 대 49%)
 - → 과제가 "AI 미탐지 조건 분석"이고 농침이 재검사보다 비싸다고 보아 **미탐지**를 우선했다
- ③ **크기**: 3.7M(15MB)로 RT-DETR-I(32.8M)의 약 1/9
- **약점**: 노이즈 보간 오경보 49%, 신뢰도가 0.9 근처에서 포화
- **대안**: 오경보 우선이면 R50 / YOLO26n, CPU 전용이면 YOLOv3-tiny
- MobileNetV3는 위치 의존·노이즈 오경보로 비권장
- 이 우선순위는 **결과를 본 뒤 정한 것**이라 보고서에 그대로 밝힌다

현장 활용: 3단 판정과 재검사 구간

실제 test에서는 결함 369장(≥ 0.748)과 빈 라벨 27장(≤ 0.04)이 완전히 갈린다

최종 모델 D-FINE-N의 임계값 운영 근거 (합성·가짜 정상은 참고용)



- 불합격 최고 신뢰도 ≥ 0.66 (val 임계값) | 재검사 0.3 ~ 0.66 | 합격 < 0.3
- 하한을 0.3으로 낮추면 오픈 점 검출 61.9% $\rightarrow$ 67.1%, 대신 가짜 정상 오경보 4.1% $\rightarrow$ 5.7%(평균 보간), 49% $\rightarrow$ 59%(노이즈 보간)
- 오경보가 비싼 현장은 재검사 구간의 이득이 작다

모델 선택 가이드와 처리 속도

촬영 간격(중양값 4초)보다 모든 모델이 빠르다

상황	권장	이유
기본(최종 모델)	D-FINE-N	val 동률 선두, 미탐지 강건성 최상, 3.7M. 노이즈 오경보 49%
오경보가 중요한 현장	Faster R-CNN R50 또는 YOLO26n	노이즈 오경보 0.5%~4.1%. R50은 느리고 YOLO26n은 3호기 합성 점에 약함
CPU 전용 / 최경량	YOLOv3-tiny	CPU 4스레드 43ms, 정확도 손실이 작음
비권장	MobileNetV3	위치 의존, 합성 점 AP 0.262, 노이즈 오경보 34~64%

처리 속도 (이미지 1장)	YOLOv3-tiny	MobileNetV3	R50	D-FINE-N	YOLO26n	RT-DETR-L
GPU (ms)	4.8	11.3	48.4	26~92	14~46	33~92
CPU 4스레드 (ms)	43	73	756	114~473	139~400	496~505

앞 3개 모델과 뒤 3개 모델은 측정 방식이 달라(전처리 포함, 두 번 측정한 범위, 실행마다 변동) 직접 비교하지 않는다. 현장 장비 사양은 알지 못한다.

차별점: 점수를 믿게 만드는 검증

못 찾은 것의 원인을 확인하고, 일반화까지 시험해 모델을 골랐다

- **오류의 원인 규명:** 놓친 것이 아니라 라벨 박스 크기 차이임을 확대 확인하고, **중심 거리 평가**로 재채점
- **점 제거 시험:** 결함을 지워 모델이 점 자체를 보는지 확인 → 지름길 우려 해소
- **가짜 정상과 합성 점:** 정상 이미지가 없는 데이터에서 오경보·미탐지 조건(열은 점, 위치, 호기)을 정량화
- **임계값과 무관한 비교:** AP·오경보 예산으로 임계값 효과를 걷어냄(D-FINE-N의 우위가 임계값 효과임을 확인)
- **공유 가능한 평가 데이터:** 시드 42 합성 데이터 + 기준본 검증으로 팀 모두가 같은 시험을 재현
- **분석을 조치로:** 취약점이 모델 선택 가이드와 재검사 구간으로 이어짐

코드 구성과 재현성

전처리 · 학습 · 추론 · 평가 · 분석을 폴더별로 분리하고 실행 명령을 문서화했다

- 환경: conda KAMP(Python 3.10), torch 2.6, 한글 경로 용 PYTHONUTF8=1, requirements.txt
- src/yolov3/: 베이스라인(호환 수정본)
- src/minyeop/: Faster R-CNN, MobileNet, YOLOv3-tiny, 팀원 모델 평가, 분석(점 제거, 가짜 정상, 합성 점, 호기 통계)
- scripts/synth_eval.py: 시드 42 합성 평가 데이터 생성기
- docs/: 지표, 실험 결과 표, 분석 해석
- 평가 규칙: 임계값은 **val에서 고정**, test는 한 번만
- 데이터 버전: manifest.csv의 sha256으로 확인
- 합성 평가 데이터: 기준본과 --verify로 비교(위치·조건·픽셀 해시)
- 모델 선정: val 부트스트랩 구간으로 "동률"을 객관적으로 판정
- 모든 수치의 출처 파일을 docs/와 runs/에 보존(예측 JSON은 제외)

한계와 향후 과제

숨기지 않고 적는다

- 합성 점과 가짜 정상은 **인위적인 이미지**다. 실제 현장 성능이 아니라 상대 비교와 취약점 탐색으로만 해석한다
- 강건성 시험은 **test 이미지**로 먼저 수행했다. 모델 선정에는 val 지표만 썼지만, 선정 근거로 쓰려면 val로 반복해야 한다
- '미탐지 우선'이라는 우선순위는 결과를 본 뒤 정했다. 오경보 우선이면 선정이 바뀐다
- 표시(색 사각형) 제거의 **흔적**이 단서가 되는지는 검증하지 못했다
- 학습 시드가 하나이고, 팀원 모델은 학습 조건이 우리와 다르다(임계값은 우리 규칙으로 재선정)
- 속도는 노트북에서 측정했고 실행마다 변동이 크다. 현장 장비 사양과 재검사 비용은 알지 못한다
- 향후: 흔적 검증(원본 BMP 2x2 실험), 실제 정상 제품 이미지 확보, val 반복, 합성 점 대조군($s=0$)

결론

- 6개 모델을 같은 조건으로 학습·평가했고 F1은 0.99 안팎이었다. 몇 개 못 찾은 것은 **공식 라벨의 박스 크기** 때문이었고 **중심 거리**로 재채점하면 거의 다 찾았다
- 일반화·robust 평가로 진짜 차이가 드러났다: **열은 결함, 노이즈 무늬 오경보, MobileNetV3의 위치 의존**
- 종합해서 **D-FINE-N**을 베스트 모델로 선정: val 동률 선두, 미탐지 강건성 최상, 작다. 약점(노이즈 오경보)은 임계값·재검사 구간과 대안 모델로 관리한다
- 공유 가능한 합성 평가 데이터와 검증 코드로 **팀 모두가 같은 시험을 재현한다**