

제6회 K-인공지능 제조데이터 분석 경진대회

점수가 포화된 X-ray 이물 검출, 점수 뒤의 진짜 성능을 검증하다

영상 기반 완제품 이물질 탐지 및 AI 미탐지 조건 분석



팀명: [확정 필요]

허민엽 · 정연창 · 이총

문제와 데이터

약 10px의 작은 점(금속구)을 찾는 검출 문제, 이미지는 모두 NG 판정


- X-ray 이물 검출기 영상 **2,532장**, 박스 4,494개
- 호기 3종, 해상도 4종 (316x332 ~ 576x444)
- train 1,767 / val 369 / test 396장 (연속 촬영 묶음 단위, 시드 42)
- **라벨이 두 종류**: 공식 500장은 크기가 제각각 (5~21px), 팀 라벨 2,032장은 **고정 크기 네모 (10·13px)** → 점수를 부풀림
- 정상 이미지가 없다(빈 라벨 105장은 제품이 반만 찍힌 사진)
- 장비의 색 표시는 지운 이미지를 사용



접근: 점수를 믿기 전에 검증한다

문제 → 의심 → 검증 → 발견 → 조치의 순서로 분석을 설계했다

이 보고서의 이야기: 점수가 포화된 데이터에서 점수 뒤의 진짜 성능을 검증한다



- 6개 모델(베이스라인 YOLOv3-tiny, Faster R-CNN 2종, 팀원 모델 3종)을 **같은 평가 코드로** 비교

기본 지표는 6개 모델이 구분되지 않는다


F1(IoU 0.5)은 0.986~0.991, 차이는 박스 정밀도(mAP50-95)에서만 난다

모델 (test)	F1	공식 라벨만 F1	mAP50-95
YOLOv3-tiny (베이스라인)	0.989	0.964	0.558
Faster R-CNN R50	0.989	0.964	0.611
Faster R-CNN MobileNetV3	0.986	0.959	0.559
YOLO26n	0.991	0.969	0.633
RT-DETR-l	0.988	0.961	0.639
D-FINE-N	0.989	0.964	0.659

- 모델 임계값은 **val**에서 **F1** 최대로 정해 고정, test는 한 번만
- 공식 라벨만 보면 F1은 0.96대로 내려간다
- mAP50-95 차이도 공식 라벨만 보면 0.335~0.365로 **좁아진다**
- → 점수 차이는 "찾는 능력"이 아니라 박스 맞춤 정밀도

지표 재설계: 중심 거리 평가


IoU 0.5는 사실상 "중심이 2px 이내인가"를 재고 있었다



- 약 10px 결함은 박스가 몇 px만 어긋나도 IoU가 급락
- "검출 중심이 정답 중심에서 R(px) 이내"로 매칭하는 평가 v2 추가
- $R \geq 3px$ 에서 6개 모델 모두 포화(F1 0.998~1.000)
- 구분은 R 1~2px의 위치 정밀도에서만 보인다

오류의 정체: 놓친 것이 아니라 박스 크기가 다른 것

test 오류 7건은 전부 공식 라벨 이미지, 점은 모두 예측 박스 안에 있다





- 모델 박스는 점을 정확히 감쌌(중심 거리 0.5~1.2px)
- 정답 박스가 더 작거나(6x7, 9x5) 더 클 뿐(14x15)
- 중심 5px 기준으로는 오류 **0건**
- → 모델의 약점이 아니라 **라벨 크기**와 **채점 기준**의 문제

점 제거 시험: 모델은 점 자체를 본다

결함의 점을 지우면 검출이 사라진다 → 위치만 보는 지름길이 아니다

점을 충분히 지우면 검출이 사라진다 → 모델은 점 자체를 본다 (위치만 보는 지름길이 아님)




- test 정답 663개의 점을 보간으로 지우고 같은 모델을 다시 적용: 노이즈 없는 평균 보간으로 13x13 이상 지우면 **6개 모델 모두 0~3개만 검출**
- YOLOv3-tiny 등에 남는 반응은 보간에 더한 **노이즈 무늬** 때문 → 다음 질문: 노이즈 무늬에 속아 오경보를 내는가?

가짜 정상 이미지: 노이즈 보간에는 R50과 YOLO26n만 속지 않는다

정상 이미지가 없어 결함의 점을 지운 이미지로 오경보를 잤다


점 제거와 가짜 정상 시험: 6개 모델 (test 결함 369장, 점 663개, 모델마다 val 임계값)



- NS+노이즈 6px 오경보율: **R50 0.5%, YOLO26n 4.1%**, RT-DETR-L 37%, YOLOv3-tiny 39%, D-FINE-N 49%, MobileNetV3 64%
- 오경보는 대부분 **지운 자리에서 발생**, 분리도(AUC)는 MobileNet 0.842·D-FINE 0.900이 가장 나쁨

합성 점 평가 데이터: 작대기 안에만, 시드 42로 모두가 같게

실제로는 농침이 사실상 없어서, 미탐지 조건을 직접 만들어 시험했다






- 실제 점을 지우고 영상에서 찾은 작대기(막대) 안쪽에만 val의 실제 점(투과율 조각)을 합성
- 점의 진하기(4단계) x 크기(3단계)를 바꿔 열린 점까지 시험
- test 바탕 386장, 점 1,436개. 실제 점 663개가 전부 검출된 막대에 닿음
- 시드 42 + 이미지 이름별 시드로 고정, 기준본과 --verify로 팀원 PC에서 같은 데이터인지 확인
- 합성은 실제보다 약 10%p 덜 현실적 → 절대 수치가 아닌 상대 비교

합성 점 결과: 열은 점이 미탐지 조건이다

val 임계값에서는 D-FINE-N이 앞서지만 대부분 느슨한 임계값 효과, 맞추면 차이가 줄어든다

합성 점(작대기 안, 시드 42) 평가: 6개 모델




- 대비(둘레-점 밝기) 6 미만은 모든 모델이 거의 0%, 20 이상에서 약 77~89%
- 임계값과 무관한 합성 점 AP: **D-FINE-N 0.574** $\approx$ **R50 0.567** > YOLOv3-tiny 0.515 $\approx$ YOLO26n 0.501 > RT-DETR-L 0.451 > **MobileNetV3 0.262**
- 3호기(대비 14 이상): MobileNetV3 4%, YOLO26n·RT-DETR-L 약 61%, R50·YOLOv3-tiny·D-FINE-N은 호기 차이가 작음

호기·해상도: 뚜렷한 효과는 확인되지 않았다

가장 낮은 그룹은 공식 라벨 박스가 76%여서 IoU 점수가 낮을 뿐이다

호기·해상도별 성능 (test, 모델별 val 고정 임계값). x축 아래 '공식 N%' = 그 그룹의 공식 라벨 박스 비율(라벨 크기가 제각각이라 IoU 점수가 낮아짐). *412x332는 박스 2개뿐



- 해상도별 공식 라벨 박스 비율이 10~76%로 달라 라벨 구성이 섞인다. 공식 라벨 이미지끼리만 비교하면 F1이 0.956~0.977로 좁아지고 구간이 겹친다
- 그룹별 표본이 작다(공식 라벨 이미지 호기별 20~36장). 합성 점에서 보인 3호기 약점은 **모델에 따라 다르다**(10번)

최종 모델: D-FINE-N

val 동물 선두 + 미탐지 강건성 최상 + 작다(3.7M)

모델	val mAP50-95 (전체 / 공식만)	합성 점 AP	가짜 정상 오경보 (NS+노이즈 6)	파라미터
D-FINE-N (선정)	0.655 / 0.343	0.574	49.3%	3.7M
RT-DETR-I	0.662 / 0.357	0.451	36.6%	32.8M
R50	0.615 / 0.337	0.567	0.5%	41.4M
YOLO26n	0.642 / 0.314	0.501	4.1%	2.5M



- R50·YOLO26n은 val에서 유의하게 낮음 (공식 라벨만이면 R50은 동물)
- **약점:** 노이즈 보간 오경보 49%, 신뢰도가 0.9 근처에서 포화
- **대안:** 오경보 우선 → R50 / YOLO26n, CPU 전용 → YOLOv3-tiny
- MobileNetV3는 위치 의존·노이즈 오경보로 비권장

- ① **동물 선두:** 전체 val에서 RT-DETR-I과 차이 -0.008 (95% 구간 $-0.016 \sim 0.000$)
- ② **강건성:** 미탐지 쪽은 D-FINE-N, 오경보 쪽은 RT-DETR-I이 낮다 → 놓침이 더 비싸다고 보아 **미탐지 우선**
- ③ **크기:** RT-DETR-I의 약 1/9

현장 활용: 3단 판정과 재검사 구간

실제 test에서는 결함 369장(≥ 0.748)과 빈 라벨 27장(≤ 0.04)이 완전히 갈린다

최종 모델 D-FINE-N의 임계값 운영 근거 (합성·가짜 정상은 참고용)



- 불합격 최고 신뢰도 ≥ 0.66 (val 임계값) | 재검사 0.3 ~ 0.66 | 합격 < 0.3
- 하한을 0.3으로 낮추면 오픈 점 검출 61.9% $\rightarrow$ 67.1%, 대신 가짜 정상 오경보 4.1% $\rightarrow$ 5.7%(평균 보간), 49% $\rightarrow$ 59%(노이즈 보간)
- 오경보가 비싼 현장은 재검사 구간의 이득이 작다

재검사 구간의 효과는 합성·가짜 정상에 기반한 참고 수치다. 재검사·농침 비용은 현장 값을 몰라 가정하지 않았다.

모델 선택 가이드와 처리 속도

촬영 간격(중양값 4초)보다 모든 모델이 빠르다

상황	권장	이유
기본(최종 모델)	D-FINE-N	val 동률 선두, 미탐지 강건성 최상, 3.7M. 노이즈 오경보 49%
오경보가 중요한 현장	Faster R-CNN R50 또는 YOLO26n	노이즈 오경보 0.5%~4.1%. R50은 느리고 YOLO26n은 3호기 합성 점에 약함
CPU 전용 / 최경량	YOLOv3-tiny	CPU 4스레드 43ms, 정확도 손실이 작음
비권장	MobileNetV3	위치 의존, 합성 점 AP 0.262, 노이즈 오경보 34~64%

처리 속도 (이미지 1장)	YOLOv3-tiny	MobileNetV3	R50	D-FINE-N	YOLO26n	RT-DETR-L
GPU (ms)	4.8	11.3	48.4	26~92	14~46	33~92
CPU 4스레드 (ms)	43	73	756	114~473	139~400	496~505

앞 3개 모델과 뒤 3개 모델은 측정 방식이 달라(전처리 포함, 두 번 측정한 범위, 실행마다 변동) 직접 비교하지 않는다. 현장 장비 사양은 알지 못한다.

차별점: 새 알고리즘이 아니라 "점수를 믿게 만드는 검증"

이 검증이 없었다면 "6개 모델 모두 F1 0.99"에서 끝났을 것이다

- **평가 재설계:** 공식·팀 라벨 분리, 중심 거리 평가, mAP50-95 → 포화된 점수 뒤의 차이를 드러냄
- **점 제거 시험:** 결함을 지워 모델이 점 자체를 보는지 확인 → 지름길 우려 해소
- **가짜 정상과 합성 점:** 정상 이미지가 없는 데이터에서 오경보·미탐지 조건(열은 점, 위치, 호기)을 정량화
- **임계값과 무관한 비교:** AP·오경보 예산으로 임계값 효과를 걷어냄(D-FINE-N의 우위가 임계값 효과임을 확인)
- **공유 가능한 평가 데이터:** 시드 42 합성 데이터 + 기준본 검증으로 팀 모두가 같은 시험을 재현
- **분석을 조치로:** 취약점이 모델 선택 가이드와 재검사 구간으로 이어짐

코드 구성과 재현성

전처리 · 학습 · 추론 · 평가 · 분석을 폴더별로 분리하고 실행 명령을 문서화했다

- 환경: conda KAMP(Python 3.10), torch 2.6, 한글 경로 용 PYTHONUTF8=1, requirements.txt
- src/yolov3/: 베이스라인(호환 수정본)
- src/minyeop/: Faster R-CNN, MobileNet, YOLOv3-tiny, 팀원 모델 평가, 분석(점 제거, 가짜 정상, 합성 점, 호기 통계)
- scripts/synth_eval.py: 시드 42 합성 평가 데이터 생성기
- docs/: 지표, 실험 결과 표, 분석 해석
- 평가 규칙: 임계값은 **val에서 고정**, test는 한 번만
- 데이터 버전: manifest.csv의 sha256으로 확인
- 합성 평가 데이터: 기준본과 --verify로 비교(위치·조건·픽셀 해시)
- 모델 선정: val 부트스트랩 구간으로 "동률"을 객관적으로 판정
- 모든 수치의 출처 파일을 docs/와 runs/에 보존(예측 JSON은 제외)

한계와 향후 과제

숨기지 않고 적는다

- 합성 점과 가짜 정상은 **인위적인 이미지**다. 실제 현장 성능이 아니라 상대 비교와 취약점 탐색으로만 해석한다
- 강건성 시험은 **test 이미지**로 먼저 수행했다. 모델 선정에는 val 지표만 썼지만, 선정 근거로 쓰려면 val로 반복해야 한다
- '미탐지 우선'이라는 우선순위는 결과를 본 뒤 정했다. 오경보 우선이면 선정이 바뀐다
- 표시(색 사각형) 제거의 **흔적**이 단서가 되는지는 검증하지 못했다
- 학습 시드가 하나이고, 팀원 모델은 학습 조건이 우리와 다르다(임계값은 우리 규칙으로 재선정)
- 속도는 노트북에서 측정했고 실행마다 변동이 크다. 현장 장비 사양과 재검사 비용은 알지 못한다
- 향후: 흔적 검증(원본 BMP 2x2 실험), 실제 정상 제품 이미지 확보, val 반복, 합성 점 대조군($s=0$)

결론

- 6개 모델의 기본 점수(F1 0.99)는 구분되지 않았다 → **평가를 다시 설계했다**
- "놓침"으로 보이던 오류는 **박스 크기 차이**였고, 진짜 약점은 **열은 결함, 노이즈 무늬 오경보, MobileNet의 위치 의존**이었다
- 최종 모델은 **D-FINE-N**: val 동률 선두, 미탐지 강건성 최상, 작다. 약점(노이즈 오경보)은 임계값·재검사 구간과 대안 모델로 관리한다
- 공유 가능한 합성 평가 데이터와 검증 코드로 **팀 모두가 같은 시험을 재현**한다